

**MBA
USP
ESALQ**

Clusterização de Municípios Brasileiros com Base em Indicadores Socioeconômicos Públicos

Everton da Silva Moraes
Rafael Henrique Roque

Introdução



Brasil

- 5.570 municípios
- Elevada diversidade territorial, racial, climática e socioeconômica
- Desafio da gestão pública, identificar perfis semelhantes entre os municípios



Benchmarking

- Comparação sistemática
- Prática que objetiva padrões de excelência
- Possibilita o alcance de níveis superiores de desempenho



Dados

- Fontes Internas ou Fontes Públicas
- Fonte Pública, Instituto Brasileiro de Geografia e Estatística (IBGE)
- Pesquisas estatísticas de grande complexidade

Objetivos

1

Desenvolver agrupamentos de municípios por diferentes grupos de indicadores (territoriais, populacionais, econômicos, sociais, educacionais e estruturais)


2

Analisar a qualidade dos agrupamentos obtidos utilizando métricas de validação (razão das variâncias, BIC, índice de silhueta e índice de Jaccard)

3

Avaliar a viabilidade de integrar esses agrupamentos dos grupos de indicadores em um modelo geral de similaridade municipal

Metodologia




Extração dos Dados

Origem	API Pública do IBGE
Abrangência	5.570 municípios brasileiros
Período	2022
Total de Indicadores Mapeados	74.164
Total de Indicadores Seleccionados	38
Total de Variáveis Criadas	38 (24 principais e 14 auxiliares)



Modelagem dos Dados



Grupo Indicador	Total de Variáveis	Total Variáveis Auxiliares
Dados Gerais	3	0
População	6	0
Educação	11	6
Saúde	9	6
Economia	6	2
Infraestrutura	3	0
Total	38	14

Modelagem dos Dados

Grupo Indicador	Variável	Descrição
Dados Gerais	VAR_01	Área Territorial (km ²)
	VAR_02	Total população (pessoas)
	VAR_03	Densidade demográfica (habitante por km ²)
População	VAR_04	% Homem (%)
	VAR_05	% Mulher (%)
	VAR_06	Idade Mediana (anos)
	VAR_07	Índice de Envelhecimento (razão)
	VAR_08	% População Urbana (%)
	VAR_09	% População Rural (%)

Modelagem dos Dados

Grupo Indicador	Variável	Descrição
Educação	VAR_10	Taxa de escolarização de 6 a 14 anos de idade (%)
	VAR_11	Número médio de anos de estudo das pessoas de 11anos ou mais de idade (anos)
	VAR_12	Quantidade de Empresas e outras organizações de Educação Infantil e Ensino Fundamental (unidades por 1.000 habitantes)
	VAR_12_1	[Auxiliar] Quantidade de Empresas e outras organizações de Educação Infantil e Ensino Fundamental (unidade)
	VAR_12_2	[Auxiliar] Total população (pessoas)

Modelagem dos Dados

Grupo Indicador	Variável	Descrição
Educação	VAR_13	Quantidade de Empresas e outras organizações de Ensino Médio (unidades por 1.000 habitantes)
	VAR_13_1	[Auxiliar] Quantidade de Empresas e outras organizações de Ensino Médio (unidade)
	VAR_13_2	[Auxiliar] Total população (pessoas)
	VAR_14	Quantidade de Empresas e outras organizações de Ensino Superior (unidades por 1.000 habitantes)
	VAR_14_1	[Auxiliar] Quantidade de Empresas e outras organizações de Ensino Superior (unidade)
	VAR_14_2	[Auxiliar] Total população (pessoas)

Modelagem dos Dados

Grupo Indicador	Variável	Descrição
Saúde	VAR_15	Taxa de Natalidade (nascidos vivos por 1.000 habitantes)
	VAR_15_1	[Auxiliar] Nascidos Vivos (pessoas)
	VAR_15_2	[Auxiliar] Total população (pessoas)
	VAR_16	Taxa de óbito crianças (óbitos de crianças até 1 ano por 1.000 nascidos vivos)
	VAR_16_1	[Auxiliar] Óbitos com idade menos de 1 ano (pessoas)
	VAR_16_2	[Auxiliar] Nascidos Vivos (pessoas)
	VAR_17	Quantidade de hospitais por mil habitantes (unidades por 1.000 habitantes)
	VAR_17_1	[Auxiliar] Quantidade de hospitais (unidade)
	VAR_17_2	[Auxiliar] Total população (pessoas)


Modelagem dos Dados

Grupo Indicador	Variável	Descrição
Economia	VAR_18	Salário médio mensal dos trabalhadores formais (salários mínimos)
	VAR_19	Salário médio mensal dos trabalhadores formais (R\$)
	VAR_20	Pessoal ocupado em postos de trabalho formais(pessoas)
	VAR_21	Taxa de Ocupação (%)
	VAR_21_1	[Auxiliar] Pessoal ocupado em postos de trabalho formais (pessoas)
	VAR_21_2	[Auxiliar] População de 18 a 65 anos (pessoas)
Infraestrutura	VAR_22	Taxa de domicílios com esgotamento sanitário por rede geral, rede pluvial ou fossa ligada à rede (%)
	VAR_23	Taxa de domicílios com coleta de lixo (%)
	VAR_24	Taxa de domicílios com internet (%)


Padronização dos Dados

Preenchimento dos valores ausentes

Antes




Depois




Padronização z-score


Antes



Depois





Desenvolvimento da Clusterização



Grupo Indicador	Par de Variáveis	Correlação de Pearson	Variável a Desconsiderar
População	VAR_04_PADR VAR_05_PADR	-1,00000	VAR_05_PADR
População	VAR_08_PADR VAR_09_PADR	-0,99391	VAR_09_PADR
Economia	VAR_18_PADR VAR_19_PADR	0,99790	VAR_19_PADR


VAR_04_PADR: % Homem
VAR_05_PADR: % Mulher
VAR_08_PADR: % População Urbana
VAR_09_PADR: % População Rural
VAR_18_PADR: Salário médio mensal dos trabalhadores formais em salários mínimos
VAR_19_PADR: Salário médio mensal dos trabalhadores formais em reais

Desenvolvimento da Clusterização




Desenvolvimento da Clusterização


Dados Gerais




População




Educação




Saúde




Economia



Infraestrutura



Refinamento da Clusterização



Métrica	Objetivo da Métrica	Interpretação	Peso
Índice de Silhueta (Silhouette Score)	Avaliação da qualidade interna do cluster e separação entre clusters	▲ Maior é melhor	0,45
Razão das Variâncias (VRC)	Avaliação da dispersão inter e intra-clusters	▲ Maior é melhor	0,30
Índice Jaccard (Jaccard)	Avaliação da estabilidade das partições	▲ Maior é melhor	0,15
Bayesian Information Criterion (BIC)	Avaliação do equilíbrio entre ajuste e complexidade	▼ Menor é melhor	0,10

Resumo da Clusterização

Grupo Indicador	Melhor k	Interpretação
Dados Gerais	120	Diferencia melhor os municípios em análises mais amplas, mas perdeu eficiência conforme os agrupamentos ficaram mais detalhados
População	115	Baixa diferença entre os municípios, indicando características populacionais relativamente semelhantes entre grande parte das cidades
Educação	495	Boa capacidade de separar municípios com perfis educacionais distintos, mantendo agrupamentos relativamente consistentes
Saúde	465	Possui capacidade de diferenciação com aumento de complexidade sem ganhos significativos de qualidade
Economia	380	Foi o grupo que melhor diferenciou os municípios com alta estabilidade dos clusters
Infraestrutura	480	Capacidade moderada de distinção entre os municípios, com reorganização dos grupos, mas sem mudanças expressivas na qualidade dos agrupamentos





Cluster Final

Melhor k

100

Interpretação

Conseguiu identificar padrões gerais de similaridade, porém com limitações para segmentações muito detalhadas



Conclusão

1

Foi possível aplicar o algoritmo k-means e desenvolver agrupamentos de municípios por diferentes grupos de indicadores (territoriais, populacionais, econômicos, sociais, educacionais e estruturais)

2

Foi confirmado a possibilidade de analisar a qualidade dos agrupamentos obtidos utilizando métricas de validação (razão das variâncias, BIC, índice de silhueta e índice de Jaccard)

3

Comprovado a viabilidade utilizar os agrupamentos dos grupos de indicadores em um modelo geral de similaridade municipal (cluster final)

Considerações Finais

Este estudo apresentou um modelo estruturado de agrupamento dos municípios brasileiros que pode ser utilizado como:

- Base para estudos futuros com dados atualizados
- Referência metodológica para aplicação de clusterização em dados socioeconômicos
- Suporte à identificação de municípios comparáveis, auxiliando práticas de benchmarking na gestão pública e análise de mercado

Obrigado