

Clusterização de Municípios Brasileiros com Base em Indicadores Socioeconômicos Públicos

Everton da Silva Moraes^{1*}; Rafael Henrique Roque²

¹ Consultor CRM. Rua Jeronimo Mariano, 152. Bloco 1, Ap 403 – Vila Cintra; 08744-350 Mogi das Cruzes, São Paulo, País

² Escola Superior de Agricultura “Luiz de Queiroz” da Universidade de São Paulo (ESALQ/USP). Doutor em Ciências (ESALQ/USP). Av. Pádua Dias, 11 – Agronomia; 13418-900 - Piracicaba, SP, Brasil

*autor correspondente: evertondasilvamoraes@gmail.com

Clusterização de Municípios Brasileiros com Base em Indicadores Socioeconômicos Públicos

Resumo

A presente pesquisa teve como objetivo aplicar o algoritmo k-means para agrupar os 5.570 municípios brasileiros com base em indicadores socioeconômicos públicos disponibilizados pelo Instituto Brasileiro de Geografia e Estatística (IBGE), com a finalidade de apoiar análises comparativas e práticas de benchmarking na gestão pública municipal. Os dados foram extraídos por meio de Application Programming Interface (API), tratados, estruturados e padronizados utilizando o método z-score. Ao todo, foram organizadas 24 variáveis distribuídas em seis grupos de indicadores: dados gerais, população, educação, saúde, economia e infraestrutura. Para cada grupo, o algoritmo k-means foi executado com valores de k variando entre 100 e 500, com incremento de cinco unidades. A qualidade das partições foi avaliada por meio da Razão das Variâncias (VRC), Índice de Silhueta, Índice Jaccard e Bayesian Information Criterion (BIC), sendo os resultados normalizados e combinados em um score ponderado para identificação do melhor número de clusters. Os resultados evidenciaram padrões distintos entre os grupos analisados. Conclui-se que a técnica de clusterização mostrou-se viável para identificar perfis municipais semelhantes. A abordagem proposta apresenta potencial como ferramenta analítica para apoiar a comparação entre municípios e subsidiar processos de planejamento e tomada de decisão na gestão pública.

Palavras-chave: IBGE; indicadores socioeconômicos; k-means; métricas de validação; clusters

Introdução

O Brasil caracteriza-se por elevada diversidade territorial, racial, climática e socioeconômica, amplamente reconhecida por estudos oficiais e acadêmicos (Carmo, 2025). Essa diversidade confere ao país vantagens em diferentes dimensões, como a multiplicidade de atividades econômicas, que contribui para a redução da dependência de mercados específicos, além da formação de um amplo mercado consumidor com demandas variadas. Entretanto, as grandes dimensões territoriais, as variações climáticas e outros fatores históricos e estruturais contribuíram, ao longo do tempo, para um desenvolvimento socioeconômico heterogêneo e desigual entre as regiões, estados e municípios brasileiros.

De acordo com o Instituto Brasileiro de Geografia e Estatística (IBGE, 2022), o território brasileiro é composto por 5.570 municípios, distribuídos entre 26 estados e o Distrito Federal. Cada uma dessas unidades possui uma gestão pública responsável por promover o

desenvolvimento econômico e social da sua respectiva população, por meio de implementação de ações, incentivos, projetos e programas de desenvolvimento local.

Nesse contexto, um dos principais desafios das gestões públicas dos municípios brasileiros consiste em identificar outros municípios com perfis socioeconômicos semelhantes e que possam servir como referência para adoção de processos, programas e métodos bem-sucedidos. Essa estratégia está associada ao conceito de benchmarking, que visa à comparação sistemática entre unidades organizacionais ou territoriais, com o objetivo de identificar oportunidades de melhoria a partir de experiências consolidadas em contextos similares.

O benchmarking, portanto, pode ser compreendido como uma prática orientada a identificação de padrões de excelência e à busca pelas melhores soluções, métodos ou práticas que possibilitem à organização ou instituição alcançar níveis superiores de desempenho (Albertin et al., 2021). Na gestão pública essa abordagem assume especial relevância, desde que sejam respeitadas as especificidades e as condições locais de cada município.

Um dos aspectos mais importantes do benchmarking é o método de obtenção de dados e informações, que pode envolver tanto fontes internas da própria organização ou instituição quanto fontes públicas (Albertin et al., 2021).

No Brasil, destaca-se o Censo Demográfico realizado pelo Instituto Brasileiro de Geografia e Estatística (IBGE), uma pesquisa estatística de grande complexidade, conduzida periodicamente, que coleta informações detalhadas sobre a população residente no território nacional (IBGE, 2025).

Com os indicadores e informações disponibilizadas pelo Censo Demográfico é possível estimular a disseminação de benchmarking entre os municípios, porém não é adequado comparar municípios com realidades socioeconômicas muito distintas. Nesse contexto surge a seguinte questão metodológica: como identificar municípios comparáveis de forma estruturada e baseada em dados?

Para responder a essa questão torna-se necessário o agrupamento dos municípios a partir de semelhanças obtidas por indicadores territoriais, populacionais, econômicos, socioeducacionais, estruturais e climáticos. Nesse sentido a técnica de clusterização é um dos principais métodos, pois permite organizar os municípios em grupos homogêneos, viabilizando comparações mais adequadas e fomentando a aplicação do benchmarking.

Nesse sentido, técnicas de clusterização se apresentam como ferramentas adequadas para identificar padrões de similaridade entre municípios. Entre essas técnicas, o algoritmo k-means destaca-se por sua simplicidade computacional, eficiência em grandes bases de dados e ampla aplicação em estudos socioeconômicos e de gestão pública, possibilitando o agrupamento de unidades territoriais de acordo com a proximidade de seus indicadores.

Diante das informações apresentadas, o objetivo geral da presente pesquisa foi aplicar o algoritmo k-means para agrupar municípios brasileiros com base em indicadores públicos, a fim de identificar perfis socioeconômicos semelhantes que possam subsidiar práticas de benchmarking em gestão pública. Para tanto, estabeleceu-se como objetivos específicos (i) desenvolver agrupamentos de municípios segundo diferentes grupos de indicadores (territoriais, populacionais, econômicos, sociais, educacionais e estruturais); (ii) analisar a qualidade dos agrupamentos obtidos utilizando métricas de validação (razão das variâncias, BIC, índice de silhueta e índice de Jaccard) e (iii) avaliar a viabilidade de integrar esses agrupamentos dos grupos de indicadores em um modelo geral de similaridade municipal.

Metodologia

Caracterização da Pesquisa

A presente pesquisa foi organizada em seis atividades principais, sendo elas: pesquisa exploratória, extração dos dados, modelagem dos dados, desenvolvimento da clusterização, seleção da configuração mais adequada e conclusão.

Inicialmente, realizou-se um levantamento bibliográfico sobre técnicas de clusterização, seguindo da obtenção de dados secundários. Na sequência, os dados foram organizados e padronizados para aplicação do algoritmo k-means, visando o agrupamento dos 5.570 municípios brasileiros com base em diferentes indicadores.

Posteriormente, foram avaliadas diferentes configurações de clusterização por meio de métricas de validação, com o objetivo de identificar a estrutura de agrupamento mais adequada. Por fim, baseado nos resultados foi dissertado e redigido a conclusão dos três objetivos do trabalho sendo eles: (i) Desenvolver agrupamentos de municípios segundo diferentes grupos de indicadores (territoriais, populacionais, econômicos, sociais, educacionais e estruturais); (ii) Analisar a qualidade dos agrupamentos obtidos utilizando métricas de validação (razão das variâncias, BIC, índice de silhueta e índice de Jaccard) e (iii) Avaliar a viabilidade de combinar esses agrupamentos dos grupos de indicadores em um modelo geral de similaridade municipal.

Extração dos dados

Os dados utilizados na presente pesquisa foram gerados e disponibilizados pelo Instituto Brasileiro de Geografia e Estatística (IBGE), que utilizam de métodos padronizados e auditáveis, assim garantindo a confiabilidade das análises. Tais dados foram obtidos por meio de requisições de *Application Programming Interface* (API) com a linguagem de programação Python. Vale ressaltar que tais origens disponibilizam dados completos de modo

que possibilitam a realização de análises comparativas e, conseqüentemente, o desenvolvimento de clusters.

O desenvolvimento realizado em Python para extração dos e tratativas utilizou das seguintes bibliotecas: *ast*, *datetime*, *json*, *os*, *pandas*, *pytz*, *re*, *requests*, *time* e *unicodedata* e buscando um ambiente de desenvolvimento e análise otimizado foi optado por criar arquivos Python por cada etapa seguinte maneira: (i) *00_discovery.py*, arquivo com as descobertas iniciais dos dados disponibilizados pelo IBGE, (ii) *funcoes_tcc.py*, arquivo que centraliza todas as funções criadas e utilizadas nesta pesquisa contém descrições detalhadas e também as documentações referências quando houver e (iii) *01_desenvolvimento.py*, arquivo que concentra o desenvolvimento dos clusters com base nas definições da etapa de descoberta.

Foram criadas funções (Tabela 1) de modo que o código fosse mais organizado e otimizado para utilizar em loops além de facilitar o entendimento das lógicas desenvolvidas, aonde salvas de maneira consolidada no arquivo *funcoes_tcc.py*.

Tabela 1. Funções desenvolvidas para extrair e tratar indicadores

Função	Descrição
log (mensagem)	Função para gerar o log/acompanhamento das execuções
tratar_nome_arquivo (texto)	Trata um texto em minúsculas, sem acentuação e sem espaços para utilizar como nome de arquivo
verificar_importar_arquivo_csv (caminho, arquivo, importa_registros, exibir_log)	Verificar se o arquivo CSV existe e realiza importação
exportar_dataframe_csv (df, caminho, arquivo, incluir_index)	Exportar o DataFrame para um arquivo CSV
consultar_existencia_dataframe(nome_dataframe, contexto)	Consultar se o DataFrame existe
consultar_conjunto_agregado (tipo_consulta, valor_consulta)	Consultar conjunto de agregados do TIPO CONSULTA = VALOR CONSULTA
consultar_metadados_agregado(id_agregado)	Consultar metadados do agregado
obter_indicadores (id_agregador, periodo, id_variavel, localidade, classificacoes)	Obter os indicadores filtrando Agregado, Período, Variável, Localidade e Classificação
obter_com_retry (url, tentativas, espera)	Faz uma requisição GET com tentativas de repetição em caso de falha.

Fonte: Dados originais da pesquisa

Baseado na estrutura e funções desenvolvidas foram realizadas as seguintes etapas para obter as amostras dos dados disponibilizados pelo IBGE: (i) obter os agregados relacionados ao período do ano 2022, que resultou em 1.636 agregados (ii) obter todos os metadados dos agregados relacionados ao ano 2022, originando 1.411.130 registros, (ii) partindo dos metadados, foram selecionados os agregados que estão relacionados ao período de 2022 e que possuem o nível de localidade N6, município, resultando em 74.164 registros.

Partindo dos metadados dos agregados relacionados ao ano 2022 que possuem o nível de localidade N6, foi realizado a extração dos 74.164 indicadores possíveis da cidade Mogi das Cruzes, município no qual possui como o Id Localidade 3530607, este município foi escolhido pela familiaridade do autor, também por sua relevância regional, diversidade socioeconômica e disponibilidade consistente dos dados, o que o tornou um caso adequado para aplicação e validação da metodologia proposta.

Com base no panorama da cidade de Mogi das Cruzes (IBGE, 2023), foram selecionados 38 indicadores considerados representativos. A escolha destes indicadores buscou replicar a estrutura analítica adotada pelo próprio IBGE, partindo do entendimento de que tais variáveis refletem os aspectos mais relevantes para caracterização municipal. Estes indicadores foram utilizados diretamente ou como base para o cálculo das variáveis empregadas na etapa de clusterização.

Os indicadores selecionados estão relacionados a 3 pesquisas: Censo Demográfico, Cadastro Central de Empresas e Pesquisa Estatísticas do Registro Civil onde estão organizadas e distribuídas em 18 agregados (Tabela 2).

Tabela 2. Agregados dos indicadores selecionados a serem utilizados na clusterização
(continua)

Pesquisa	Agregado
CD	4714 - População Residente, Área territorial e Densidade demográfica
CD	6805 - Domicílios particulares permanentes ocupados, por tipo de esgotamento sanitário
CD	6892 - Domicílios particulares permanentes ocupados, por destino do lixo
CD	9515 - Índice de envelhecimento, idade mediana e razão de sexo da população
CD	9543 - Taxa de alfabetização das pessoas de 15 anos ou mais de idade por sexo, cor ou raça e grupos de idade
CD	9606 - População residente, por cor ou raça, segundo o sexo e a idade
CD	9756 - Índice de envelhecimento, idade mediana e razão de sexo, por cor ou raça
CD	9936 - Domicílios particulares permanentes ocupados, por existência de conexão domiciliar à Internet, condição de ocupação do domicílio e tipo do domicílio
CD	10051 - Estabelecimentos de saúde, ensino e outras finalidades, em setores selecionados para a Pesquisa Urbanística do Entorno dos Domicílios, por existência e características do entorno
CD	10056 - Taxa bruta de frequência escolar, segundo os grupos de idade, o sexo e a cor ou raça
CD	10062 - Número médio de anos de estudo das pessoas com 11 anos ou mais de idade, segundo os grupos de idade, o sexo e a cor ou raça
CD	10089 - População residente, total e quilombola, por sexo e grupos de idade, segundo localização e situação do domicílio
CD	10135 - Taxa de analfabetismo das pessoas de 15 anos ou mais de idade por grupo de idade, cor ou raça, sexo e existência de deficiência
CD	10150 - Taxa de escolarização das pessoas de 6 anos ou mais de idade, total e pessoas diagnosticadas com autismo, por sexo e grupo de idade

Tabela 3. Agregados dos indicadores selecionados a serem utilizados na clusterização (conclusão)

Pesquisa	Agregado
CL	9418 - Empresas e outras organizações, pessoal ocupado total, pessoal ocupado assalariado, salários e outras remunerações, por seção, divisão, grupo e classe da classificação de atividades (CNAE 2.0)
CL	9509 - Unidades locais, empresas e outras organizações atuantes, pessoal ocupado total, pessoal ocupado assalariado, pessoal assalariado médio, salários e outras remunerações e salário médio mensal
RC	2609 - Nascidos vivos, por ano de nascimento, grupos de idade da mãe na ocasião do parto, sexo e lugar de residência da mãe
RC	2681 - Óbitos, ocorridos no ano, por mês de ocorrência, natureza do óbito, sexo, idade, local de ocorrência e lugar do registro

Fonte: Dados originais da pesquisa

Nota: CD: Censo Demográfico, CL: Cadastro Central de Empresas, RC: Pesquisa Estatísticas do Registro Civil

Partindo destes agregados foram selecionadas 22 variáveis para o desenvolvimento de clusterização (Tabela 3).

Tabela 4. Variáveis dos indicadores selecionados a serem utilizados na clusterização (continua)

Id Agregado	Variável
4714	93 - População residente (pessoas)
4714	6318 - Área da unidade territorial (Km ²)
4714	614 - Densidade demográfica (habitante por Km ²)
6805	1000381 - Domicílios particulares permanentes ocupados - percentual do total geral (%)
6892	1000381 - Domicílios particulares permanentes ocupados - percentual do total geral (%)
9515	10612 - Índice de envelhecimento (razão)
9543	2513 - Taxa de alfabetização das pessoas de 15 anos ou mais de idade (%)
9606	93 - População residente (pessoas)
9606	1000093 - População residente - percentual do total geral (%)
9756	10613 - Idade mediana (anos)
9936	1000381 - Domicílios particulares permanentes ocupados - percentual do total geral (%)
10051	13324 - Quantidade de estabelecimentos de saúde, ensino e outras finalidades, em setores selecionados para a Pesquisa Urbanística do Entorno dos Domicílios (unidades)
10056	3795 - Taxa de frequência escolar bruta (%)
10062	13285 - Número médio de anos de estudo das pessoas de 11 anos ou mais de idade (anos)
10089	1000093 - População residente - percentual do total geral (%)
10135	10267 - Taxa de analfabetismo das pessoas de 15 anos ou mais de idade (%)
10150	12805 - Taxa de escolarização das pessoas de 6 anos ou mais de idade (%)
9418	2585 - Número de empresas e outras organizações (unidades)
9509	707 - Pessoal ocupado total (pessoas)

Tabela 5. Variáveis dos indicadores selecionados a serem utilizados na clusterização (conclusão)

Id Agregado	Variável
9509	1606 - Salário médio mensal (salários mínimos)
9509	10143 - Salário médio mensal em reais (R\$)
2609	217 - Nascidos vivos registrados no ano (pessoas)
2681	343 - Número de óbitos ocorridos no ano (pessoas)

Fonte: Dados originais da pesquisa

Nota: Cada variável está atrelada ao um agregado, as descrições dos agregados estão na tabela anterior (Tabela 2).

Algumas variáveis possuem classificação, proporcionando mais detalhe ou visão sobre os indicadores, sendo assim foi obtido 38 combinações finais de variáveis e classificações (Tabela 4).

Tabela 6. Combinação de Agregados, Variáveis e Classificações dos indicadores selecionados a serem utilizados na clusterização

(continua)

Variável	Classificação
93 - População residente (pessoas)	
614 - Densidade demográfica (habitante por Km ²)	
6318 - Área da unidade territorial (Km ²)	
1000381 - Domicílios particulares permanentes ocupados - percentual do total geral (%)	Tipo de esgotamento sanitário: Rede geral, rede pluvial ou fossa ligada à rede
1000381 - Domicílios particulares permanentes ocupados - percentual do total geral (%)	Destino do lixo: Coletado
10612 - Índice de envelhecimento (razão)	
2513 - Taxa de alfabetização das pessoas de 15 anos ou mais de idade (%)	Total
93 - População residente (pessoas)	Idade: 18 anos
93 - População residente (pessoas)	Idade: 19 anos
93 - População residente (pessoas)	Idade: 65 anos
93 - População residente (pessoas)	Idade: 20 a 24 anos
93 - População residente (pessoas)	Idade: 25 a 29 anos
93 - População residente (pessoas)	Idade: 30 a 34 anos
93 - População residente (pessoas)	Idade: 35 a 39 anos
93 - População residente (pessoas)	Idade: 40 a 44 anos
93 - População residente (pessoas)	Idade: 45 a 49 anos
93 - População residente (pessoas)	Idade: 50 a 54 anos
93 - População residente (pessoas)	Idade: 55 a 59 anos
93 - População residente (pessoas)	Idade: 60 a 64 anos
1000093 - População residente - percentual do total geral (%)	Sexo: Homens
1000093 - População residente - percentual do total geral (%)	Sexo: Mulheres

Tabela 7. Combinação de Agregados, Variáveis e Classificações dos indicadores selecionados a serem utilizados na clusterização

Variável	Classificação
10613 - Idade mediana (anos)	Total
1000381 - Domicílios particulares permanentes ocupados - percentual do total geral (%)	Existência de conexão domiciliar à Internet: Sim
13324 - Quantidade de estabelecimentos de saúde, ensino e outras finalidades, em setores selecionados para a Pesquisa Urbanística do Entorno dos Domicílios (unidades)	Espécie: Estabelecimento de saúde
3795 - Taxa de frequência escolar bruta (%)	Grupo de Idade: 6 a 14 anos
13285 - Número médio de anos de estudo das pessoas de 11 anos ou mais de idade (anos)	Total
1000093 - População residente - percentual do total geral (%)	Situação do domicílio: Urbana
1000093 - População residente - percentual do total geral (%)	Situação do domicílio: Rural
10267 - Taxa de analfabetismo das pessoas de 15 anos ou mais de idade (%)	Total
12805 - Taxa de escolarização das pessoas de 6 anos ou mais de idade (%)	Grupo de idade: 6 a 14 anos
2585 - Número de empresas e outras organizações (unidades)	Classificação Nacional de Atividades Econômicas (CNAE 2.0): 85.1 Educação infantil e ensino fundamental
2585 - Número de empresas e outras organizações (unidades)	Classificação Nacional de Atividades Econômicas (CNAE 2.0): 85.2 Ensino médio
2585 - Número de empresas e outras organizações (unidades)	Classificação Nacional de Atividades Econômicas (CNAE 2.0): 85.3 Educação superior
707 - Pessoal ocupado total (pessoas)	
1606 - Salário médio mensal (salários mínimos)	
10143 - Salário médio mensal em reais (R\$)	
217 - Nascidos vivos registrados no ano (pessoas)	Ano de nascimento: 2022
343 - Número de óbitos ocorridos no ano (pessoas)	Idade do(a) falecido(a): Menos de 1 ano

Fonte: Dados originais da pesquisa

Nota: Existem variáveis que não possuem classificação disponibilizada pela API do IBGE

Modelagem dos dados

Os dados das 38 variáveis (Tabela 4) obtidos a partir da API de dados agregados do IBGE são disponibilizados em formato *JavaScript Object Notation* (JSON), consistindo um formato simples que possibilita a criação de conjuntos de chave-valor com extrema flexibilidade (Banhara et al., 2023), mas para o desenvolvimento da clusterização foi

necessário implementar a primeira ação de modelagem de dados, transformando estas informações para uma modelo relacional, modelo quem que as informações são organizadas em tabelas de forma que cada linha seja um registro e que este registro seja uma estrutura com número determinado de campos e características (Cardoso et al., 2012).

Partindo dos indicadores obtidos e entendendo que o modelo relacional é o mais adequado para o desenvolvimento da clusterização foi elaborado uma tabela única com 38 variáveis, destes 14 são variáveis auxiliares utilizadas no cálculo de outra variável e 24 variáveis serão utilizadas nas próximas etapas, onde a definição destas 24 variáveis foi orientado para a replicação dos indicadores existentes no panorama das cidades (IBGE, 2023), todas as variáveis foram organizadas em grupos de indicadores (Tabela 5).

Tabela 8. Variáveis criadas para o desenvolvimento da clusterização

(continua)

Variável	Grupo Indicador	Descrição
VAR_01	Dados Gerais	Área Territorial (km ²)
VAR_02	Dados Gerais	Total população (pessoas)
VAR_03	Dados Gerais	Densidade demográfica (habitante por km ²)
VAR_04	População	% Homem (%)
VAR_05	População	% Mulher (%)
VAR_06	População	Idade Mediana (anos)
VAR_07	População	Índice de Envelhecimento (razão)
VAR_08	População	% População Urbana (%)
VAR_09	População	% População Rural (%)
VAR_10	Educação	Taxa de escolarização de 6 a 14 anos de idade (%)
VAR_11	Educação	Número médio de anos de estudo das pessoas de 11 anos ou mais de idade (anos)
VAR_12	Educação	Quantidade de Empresas e outras organizações de Educação Infantil e Ensino Fundamental (unidades por 1.000 habitantes)
VAR_12_1	[Auxiliar] Educação	Quantidade de Empresas e outras organizações de Educação Infantil e Ensino Fundamental (unidade)
VAR_12_2	[Auxiliar] Educação	Total população (pessoas)
VAR_13	Educação	Quantidade de Empresas e outras organizações de Ensino Médio (unidades por 1.000 habitantes)
VAR_13_1	[Auxiliar] Educação	Quantidade de Empresas e outras organizações de Ensino Médio (unidade)
VAR_13_2	[Auxiliar] Educação	Total população (pessoas)
VAR_14	Educação	Quantidade de Empresas e outras organizações de Ensino Superior (unidades por 1.000 habitantes)
VAR_14_1	[Auxiliar] Educação	Quantidade de Empresas e outras organizações de Ensino Superior (unidade)
VAR_14_2	[Auxiliar] Educação	Total população (pessoas)
VAR_15	Saúde	Taxa de Natalidade (nascidos vivos por 1.000 habitantes)
VAR_15_1	[Auxiliar] Saúde	Nascidos Vivos (pessoas)
VAR_15_2	[Auxiliar] Saúde	Total população (pessoas)

Tabela 5. Variáveis criadas para o desenvolvimento da clusterização

(conclusão)

Variável	Grupo Indicador	Descrição
VAR_16	Saúde	Taxa de óbito crianças (óbitos de crianças até 1 ano por 1.000 nascidos vivos)
VAR_16_1	[Auxiliar] Saúde	Óbitos com idade menos de 1 ano (pessoas)
VAR_16_2	[Auxiliar] Saúde	Nascidos Vivos (pessoas)
VAR_17	Saúde	Quantidade de hospitais por mil habitantes (unidades por 1.000 habitantes)
VAR_17_1	[Auxiliar] Saúde	Quantidade de hospitais (unidade)
VAR_17_2	[Auxiliar] Saúde	Total população (pessoas)
VAR_18	Economia	Salário médio mensal dos trabalhadores formais (salários mínimos)
VAR_19	Economia	Salário médio mensal dos trabalhadores formais (R\$)
VAR_20	Economia	Pessoal ocupado em postos de trabalho formais (pessoas)
VAR_21	Economia	Taxa de Ocupação (%)
VAR_21_1	[Auxiliar] Economia	Pessoal ocupado em postos de trabalho formais (pessoas)
VAR_21_2	[Auxiliar] Economia	População de 18 a 65 anos (pessoas)
VAR_22	Infraestrutura	Taxa de domicílios com esgotamento sanitário por rede geral, rede pluvial ou fossa ligada à rede (%)
VAR_23	Infraestrutura	Taxa de domicílios com coleta de lixo (%)
VAR_24	Infraestrutura	Taxa de domicílios com internet (%)

Fonte: Dados originais da pesquisa

Nota: As nomenclaturas das variáveis foram criadas de forma abreviada objetivando uso otimizado no script

Padronização

Com os dados organizados em forma de tabelas, faz-se necessário realizar o processo de padronização, com o objetivo de eliminar possíveis distorções causadas pelas diferenças de escala entre as variáveis (Hair Jr et al., 2009). Sem essa etapa, o algoritmo poderia atribuir pesos desproporcionais às variáveis, como no caso de uma variável medida em quilômetros quadrados e outra expressa em percentuais, comprometendo a formação adequada dos clusters.

As variáveis foram padronizadas por meio do z-score com a implementação da função *StandardScale* do módulo *preprocessing* da biblioteca *scikit-learn*, no qual ajusta os valores de maneira que apresentam uma média igual a 0 e desvio padrão igual a 1. Este método calcula quantos desvios padrão um determinado valor se encontra acima ou abaixo da média (Silva, 2024), assim permitindo a comparação entre variáveis em diferentes escalas e garantindo maior consistência para a aplicação do algoritmo k-means.

A padronização z-score é calculado por meio da form. (1):

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

em que: x: valor original; μ : média da variável; e σ : desvio padrão da variável.

Para os municípios que não apresentavam valores registrados para determinada variável, adotou-se como procedimento de padronização o preenchimento das ausências com a mediana da respectiva variável.

Com as variáveis padronizadas, a análise de correlação de Pearson foi realizada, sendo esta uma métrica que avalia a força de relacionamento entre duas variáveis considerando a associação simultânea. O coeficiente de correlação de Pearson varia de -1 a 1, sendo que quando a métrica obtida é um dos valores extremos (-1 ou 1) indica uma correlação perfeita evidenciando que a variação de uma variável está completamente relacionada a variação da outra variável e o sinal positivo indica associação diretamente proporcional e o negativo indica associação inversamente proporcional (Figueiredo Filho e Silva Jr, 2009).

Desenvolvimento da clusterização

Clusterização ou clustering é uma técnica de aprendizado de máquina não supervisionado que tem como objetivo identificar padrões de similaridade entre objetos, agrupando-os de acordo com suas características (Sousa, 2019). Em termos conceituais, elementos mais semelhantes tendem a apresentar menores distâncias entre si no espaço multidimensional dos dados, enquanto elementos menos similares se afastam, formando grupos distintos.

Uma das formas mais utilizadas para desenvolver uma clusterização é por meio do algoritmo k-means, que busca particionar os dados em um número pré-determinado de agrupamentos (Jake, 2025). O método funciona iterativamente a partir da definição de centroides, que representam o centro de cada cluster com base na média aritmética das observações atribuídas a ele. A cada iteração, calcula-se a distância de cada ponto aos centroides e cada elemento é realocado ao cluster cujo centro estiver mais próximo, ajustando-se continuamente os centroides até que o algoritmo atinja estabilidade.

Após a modelagem dos dados, através da função *kmeans* da biblioteca *scikit-learn*, foi aplicado o algoritmo k-means onde foram criados de 100 a 500 clusters por cada grupo de indicadores buscando criar agrupamentos de 11 a 55 municípios, de modo que seja gerado grupos com tamanhos factíveis para análises futura. Porém devido ao risco de alto consumo de processamento computacional que poderia ocasionar em interrupções durante o processamento associado à execução repetida do algoritmo para múltiplos valores de k, foi adotado o incremento de 5 entre os valores de k, de modo que permitiu reduzir o processamento e o risco de interrupções sem comprometer de forma significativa a granularidade da análise (Figura 1).

```
# Loop nos ks
for k in k_values:

    log(f"Executando K-Means com {k} clusters...")

    # K-Means
    kmeans = KMeans(
        n_clusters=k
        ,random_state=42
        ,n_init=10
    )
    clusters_atual = kmeans.fit_predict(df_variaveis)
```

Figura 1. Trecho do script que implementa o kmeans em loop conforme os valores do k_values
Fonte: Resultados originais da pesquisa

Nota: k_values é lista de quantidade de clusters a serem gerados de 100 a 500 com incremento 5 em 5 e df_variaveis é conjunto de dados com todas as variáveis

Refinamento da clusterização

Com base em um índice de validação, é possível avaliar a qualidade dos agrupamentos gerados e, a partir disso, definir a estratégia mais apropriada para a execução do k-means. O algoritmo foi executado com distintas inicializações, permitindo comparar os resultados obtidos. O modelo final foi selecionado considerando o desempenho mensurado pelo índice de validação elegido (Fontana e Naldi, 2009).

Para a seleção do índice de validação, foram considerados diferentes critérios, entre eles: (i) razão das variâncias (VRC), que estima a semelhança dos elementos do cluster e o afastamento exterior entre os grupos; (ii) Bayesian Information Criterion (BIC), que incide na avaliação do equilíbrio entre o incremento de informação do modelo ao acréscimo de complexidade através de crescente volume de parâmetros; (iii) índice de silhueta, baseados na afinidade entre os elementos do grupo e na distância destes elementos ao grupo mais próximo e (iv) índice Jaccard, que mede o grau de afinidade entre grupos de amostras, calculando a possibilidade que dois objetos pertencem ao mesmo grupo em ambas as partições.

A razão das variâncias, do inglês Variance Ratio Criterion (VRC), é uma métrica que avalia a qualidade da clusterização através da avaliação da semelhança interna do cluster com o afastamento dos outros grupos, onde quando melhor a qualidade da partição, maior será o valor desta razão. O cálculo desta métrica é realizado pela form. (2) (Naldi, 2011):

$$VRC(\pi) = \frac{BGSS(\pi)}{WGSS(\pi)} \times \frac{(n_0 - k)}{(k - 1)} \quad (2)$$

em que: BGSS(π): soma das distâncias quadráticas entre os grupos de uma partição π , calculado pela form. (3); WGSS(π): é a soma das distâncias quadráticas internas aos grupos de uma partição π , calculado pela form. (4); n_0 : total de elementos do conjunto de dados; e k: quantidade de clusters,

$$BGSS(\pi) = \sum_{i=1}^k BGSS(C_i), \quad (3)$$

$$WGSS(\pi) = \sum_{i=1}^k WGSS(C_i) \quad (4)$$

em que: k : é o número de grupos da partição; $BGSS(C_i)$: soma das distâncias quadráticas entre o grupo C_i e a média dos objetos calculado pela form. (5); e $WGSS(C_i)$: soma das distâncias quadráticas relacionadas ao C_i calculado pela form. (6)

$$BGSS(C_i) = |C_i|(c_i - \bar{x})^T(c_i - \bar{x}), \quad (5)$$

$$WGSS(C_i) = \sum_{x_j \in C_i} (x_j - c_i)^T(x_j - c_i) \quad (6)$$

em que: $|C_i|$: cardinalidade do conjunto C_i ; c_i : centroide do grupo C_i ; $\bar{x}$: média de todos os objetos do conjunto X ; x_j : j -ésimo observação que pertencente ao conjunto C_i .

A razão das variâncias foi calculada baseado nas fórmulas apresentadas anteriormente e nas bibliotecas funções *mean* e *sum* da biblioteca *numpy*, atributos *cluster_centers_* e *inertia_* da instância da classe *kmeans* da biblioteca *scikit-learn* (Figura 2).

```
# Razão das variâncias (VRC)

# Média global dos dados (x̄)
x_barra = np.mean(df_variaveis, axis=0)

# BGSS(π) = soma das distâncias quadráticas entre clusters
BGSS_pi = sum([
    len(df_variaveis[clusters_atual==i])
    * np.sum((kmeans.cluster_centers_[i] - x_barra)**2)
    for i in range(k)])

# WGSS(π) = soma das distâncias quadráticas intra-clusters
WGSS_pi = kmeans.inertia_

# Número total de observações (n₀)
n0 = len(df_variaveis)

# Variance Ratio Criterion (VRC)
VRC_pi = (BGSS_pi / WGSS_pi)*((n0 - k)/(k-1))
```

Figura 2. Trecho do script que realiza o cálculo da razão das variâncias (VRC) utilizando as bibliotecas *numpy* e *scikit-learn*

Fonte: Resultados originais da pesquisa

O Bayesian Information Criterion (BIC) calcula o equilíbrio entre ajustes e complexidade (Fontana e Naldi, 2009) e quanto menor o BIC, melhor este equilíbrio.

Para calcular o BIC foi utilizado o Modelo de Mistura Gaussianada (Gaussian Mixture Model – GMM) a partir da implementação da classe *GaussianMixture* da biblioteca *scikit-learn* (Figura 3).


```
# BIC via GaussianMixture
gmm = GaussianMixture(n_components=k
                       , covariance_type='full'
                       , random_state=42)
gmm.fit(df_variaveis)
bic = gmm.bic(df_variaveis)
```

Figura 3. Trecho do script que realiza o cálculo Bayesian Information Criterion (BIC) através da implementação da classe *GaussianMixture*

Fonte: Resultados originais da pesquisa

Nota: k é quantidade de clusters, df_variaveis é conjunto de dados com todas as variáveis

O índice de silhueta foi calculado utilizando a função *silhouette_score* da biblioteca *scikit-learn* (Figura 4), na qual automaticamente realiza o cálculo das distâncias e coeficiente médio de silhueta, avaliando se os objetos estão bem situados em seu grupo e quanto melhor situados os objetos, maior será esta métrica (Fontana e Naldi, 2009).

```
# Silhouette Score
sil = silhouette_score(df_variaveis
                      , clusters_atual)
```

Figura 4. Trecho do script que realiza o cálculo índice de silhueta ou silhouette score através da implementação da função *silhouette*

Fonte: Resultados originais da pesquisa

Nota: df_variaveis é o conjunto de dados com as variáveis e clusters_atual são os clusters gerados pelo k-means

O índice Jaccard é calculado pela form. (7) (Naldi, 2011):

$$Jaccard(\pi_r, \pi_g) = \frac{np_{11}}{np_{11} + np_{01} + np_{10}} \quad (7)$$

em que: π_r : partição de referência, obtida na iteração anterior; π_g : partição a ser comparada, obtida na iteração atual; np_{11} : número de pares de observação que pertencem ao mesmo cluster em π_r e pertencem ao mesmo cluster em π_g ; np_{01} : número de pares de observação que pertencem a clusters diferentes em π_r mas pertencem ao mesmo cluster em π_g ; np_{10} : número de pares de observação que pertencem ao mesmo cluster em π_r mas pertencem a clusters diferentes em π_g ;

O índice Jaccard foi implementado utilizando o cálculo apresentado anteriormente através da biblioteca *numpy* (Figura 5). Quanto mais idênticas forem as clusterizações comparadas, mais próximo de 1 será o valor da métrica (Fontana e Naldi, 2009). Desta maneira, sugerindo estabilidade no processo de clusterização e, conseqüentemente redução dos ganhos potenciais nas execuções de novas clusterizações.


```
# Índice Jaccard
def jaccard_index(pi_r, pi_g, sample_size=3000):

    n0 = len(pi_r)

    # Amostragem, se necessário
    if sample_size and n0 > sample_size:
        idx = np.random.choice(n0, sample_size, replace=False)
        pi_r = pi_r[idx]
        pi_g = pi_g[idx]

    # Matrizes de coassociação:
    # A_r(i,j) = 1 se i e j pertencem ao mesmo cluster em n_r
    # A_g(i,j) = 1 se i e j pertencem ao mesmo cluster em n_g
    A_r = (pi_r[:, None] == pi_r[None, :])
    A_g = (pi_g[:, None] == pi_g[None, :])

    # np_11: pares no mesmo cluster em ambas as partições
    np_11 = np.logical_and(A_r, A_g).sum()

    # np_10: pares no mesmo cluster em n_r e em clusters diferentes em n_g
    np_10 = np.logical_and(A_r, np.logical_not(A_g)).sum()

    # np_01: pares no mesmo cluster em n_g e em clusters diferentes em n_r
    np_01 = np.logical_and(np.logical_not(A_r), A_g).sum()

    # Índice de Jaccard
    return np_11 / (np_11 + np_01 + np_10)

## Jaccard (comparando com cluster anterior, se existir)
jaccard = np.nan
if clusters_anterior is not None:
    jaccard = jaccard_index(clusters_anterior
                           ,clusters_atual
                           ,sample_size=len(clusters_anterior))

    clusters_anterior = clusters_atual # armazena para próxima comparação
```

Figura 5. Trecho do script que realiza o cálculo o índice Jaccard utilizando as bibliotecas *numpy*

Fonte: Resultados originais da pesquisa

Nota: *clusters_anterior* é o conjunto de clusters calculados na iteração ou etapa anterior e *clusters_atual* é o conjunto de clusters calculados na iteração ou etapa atual

Considerando que as 4 métricas apresentadas (razão das variâncias (VRC), Bayesian Information Criterion (BIC), índice de silhueta e índice Jaccard) possuem escalas distintas e interpretações diferentes, foi necessário realizar a padronização min-max dos valores form. (8) utilizando a função *MinMaxScaler* do módulo *preprocessing* da biblioteca *scikit-learn*.

$$\tilde{m} = \frac{m - m_{\min}}{m_{\max} - m_{\min}} \quad (8)$$

em que: *m*: valor original da métrica; *m_{min}*: é o valor mínimo da métrica; e *m_{max}*: é o valor máximo da métrica.

Para a métrica BIC foi necessário aplicar a inversão do valor padronizado uma vez que esta métrica é de minimização, form. (9).

$$\widetilde{BIC}_k = 1 - \widetilde{BIC}_k \quad (9)$$

em que: $\widehat{BIC}_k$: valor padronizado da métrica BIC um determinado k; k: número de clusters; p: quantidade de métricas; e $\widehat{m}_i$: valor padronizado da i-ésima métrica associada ao k.

Partindo dos indicadores normalizados e objetivando identificar o melhor k foi considerando as seguintes prioridades: (i) melhor afinidade interna entre os elementos dos clusters e o distanciamento com o grupo mais próximo, (ii) dispersão interna e entre os clusters, (iii) estabilidade dos clusters e (iv) menor complexidade, foi determinado pesos distintos para os indicadores normalizados a serem utilizados no cálculo do score (Tabela 6)

Tabela 9. Pesos Indicadores

Indicador	Peso	Justificativa
Índice de silhueta - Silhouette Score	0,45	Qualidade interna e separação
Razão das variâncias - VRC	0,30	Dispersão inter e intra-clusters
Índice jaccard - Jaccard	0,15	Estabilidade das partições
Bayesian Information Criterion - BIC	0,10	Penalização de complexidade

Fonte: Dados originais da pesquisa

Nota: Pesos determinados por indicador a ser utilizado no cálculo do score para o obter o melhor k

Com os pesos definidos respeitando as prioridades foi calculado o score por cada k, form. (10).

$$S_k = 0,45.\widehat{SS}_k + 0,30.\widehat{VRC}_k + 0,15.\widehat{J}_k + 0,10.\widehat{BIC}_k \quad (10)$$

em que: S_k : score calculado para determinado k; k: número de clusters; $\widehat{SS}_k$: silhouette score ou critério de silhueta normalizado associado ao k; $\widehat{VRC}_k$: razão das variâncias normalizado associado ao k; $\widehat{J}_k$: índice jaccard associado ao k; e $\widehat{BIC}_k$: bayesian information critério ou BIC associado ao k

Depois de calculado o score para cada k, foi o obtido o melhor k através da busca do maior score através da form. (11).

$$k^* = \arg \max_k S_k \quad (11)$$

em que: S_k : é o score calculado para um determinado k; e k: número de clusters

Para realizar o cálculo dos scores e a identificação do melhor k foi utilizado as funções *copy*, *mean*, *loc* e *idxmax* da biblioteca *pandas*, as funções *standardscaler*, *fit_transform* da biblioteca *scikit-learn* (Figura 6).

```
def identificar_melhor_k(df_metricas):  
  
    # Cópia o DataFrame para evitar risco de alterar o original  
    df = df_metricas.copy()  
  
    # Determina as métricas a utilizar no score  
    metricas_score = ['Razao_Variancia', 'BIC', 'Silhouette_Score', 'Indice_Jaccard']  
  
    # Colunas a normalizar, exceto a k  
    #colunas_para_normalizar = [col for col in df.columns if col != 'k']  
    colunas_para_normalizar = [col for col in metricas_score]  
  
    # Pipeline: normalização (MinMax | Scalling)  
    pipeline = Pipeline([  
        ('scaler', MinMaxScaler())          # MinMax normaliza entre 0 e 1  
    ])  
  
    # Executa pipeline e normaliza os dados  
    df[colunas_para_normalizar] = pipeline.fit_transform(df[colunas_para_normalizar])  
    df_norm = df  
  
    # Inversão explícita do BIC (métrica de minimização)  
    df_norm['BIC'] = 1-df_norm['BIC'] # MinMax  
  
    # Cálculo do score ponderado  
    df_norm['Score'] = (0.45 * df_norm['Silhouette_Score'])  
    + (0.30 * df_norm['Razao_Variancia'])  
    + (0.15 * df_norm['Indice_Jaccard'])  
    + (0.10 * df_norm['BIC'])  
  
    # Melhor k  
    melhor_k = df_norm.loc[df_norm['Score'].idxmax(), 'k']  
    log(f"✅ Identificado o melhor k: {melhor_k}")  
  
    return melhor_k, df_norm
```

Figura 6. Trecho do script que normaliza as métricas, calcula o score e identifica o melhor k baseado score no utilizando as bibliotecas *pandas* e *scikit-learn*

Fonte: Resultados originais da pesquisa

Nota: df_metricas é o conjunto de métricas de todos os k executados na etapa de clusterização

Resultados e Discussão

A primeira etapa desta pesquisa foi a extração de dados realizada por meio de requisições de *Application Programming Interface* (API) com a linguagem de programação Python disponibilizadas pelo Instituto Brasileiro de Geografia e Estatística (IBGE), sendo extraídas 38 combinações finais de variáveis e classificações (Tabela 4) que posteriormente foram tratadas e modeladas em 38 variáveis, sendo 14 são variáveis auxiliares e 24 variáveis principais, disponibilizadas em uma tabela única de modo que nesta tabela estas variáveis foram organizadas em grupos de indicadores (Tabela 5).

Destas 38 variáveis tratadas, identificou-se que existem variáveis que não foram obtidas para todos os 5.570 municípios (Figura 7).




Figura 7. Histograma com a quantidade de municípios com dados disponíveis por variável, evidenciando a existência de valores ausentes

Fonte: Dados originais da pesquisa

Além do cenário de município com valores ausentes, também foi confirmado que estas variáveis possuem escalas distintas e amplitude entre si (Figura 8).




Figura 8. Boxplot das variáveis evidenciando as diversas escalas e amplitudes entre as variáveis

Fonte: Dados originais da pesquisa

Baseado nas análises anteriores foi implementada a padronização, iniciado com o preenchimento com a mediana para os casos que possuem ausência de valores, garantindo o preenchimento para todos os municípios em todas as variáveis. A escolha pela mediana, em detrimento pela média, justifica-se por sua menor sensibilidade a valores extremos, outliers, comuns em indicadores socioeconômicos municipais, assim preservando uma representação mais robusta e menos distorcida da distribuição dos dados. (Figura 9).




Figura 9. Histograma com a quantidade de municípios com dados disponíveis por variável após a primeira etapa de padronização, evidenciando o preenchimento de todas as variáveis para todos os municípios

Fonte: Dados originais da pesquisa

Após a primeira etapa da padronização, preenchimento dos casos com valores ausente, foi aplicado a padronização das variáveis por meio do z-score, assim padronizando todas as variáveis a média igual a 0 e desvio padrão igual a 1 (Figura 10).




Figura 10. Boxplot das variáveis evidenciando a padronização z-score

Fonte: Dados originais da pesquisa

Com as variáveis padronizadas, avaliou-se a presença de correlações elevadas entre variáveis, uma vez que este cenário pode proporcionar redundância e distorcer o desempenho do algoritmo. Para isto, foi realizada a análise de correlação de Pearson, permitindo identificar a força de relacionamento entre os pares de variáveis e mitigar possíveis sobreposições de informação (Figura 11).




Figura 11. Matriz de correlações de Pearson das variáveis padronizadas para avaliar a força de relacionamento entre os pares
Fonte: Resultados originais da pesquisa

Partindo das correlações de Pearson obtidas, foram selecionados os pares de variáveis que possuem correlações acima de 0,99 ou abaixo de -0,99 e posteriormente escolhido a última variável dos pares ordenados de ordem alfabética para serem desconsiderados na etapa de desenvolvimento da clusterização (Tabela 7).

Tabela 10. Pares de variáveis com correlações acima de 0,99 ou abaixo de -0,99

Grupo Indicador	Par de Variáveis	Correlação de Pearson	Variável a Desconsiderar
População	VAR_04_PADR e VAR_05_PADR	-1,00000	VAR_05_PADR
População	VAR_08_PADR e VAR_09_PADR	-0,99391	VAR_09_PADR
Economia	VAR_18_PADR e VAR_19_PADR	0,99790	VAR_19_PADR

Fonte: Resultados originais da pesquisa

Com as variáveis com alta correlação terem sido desconsideradas foi gerado a clusterização dos municípios por grupo de indicadores, como citado anteriormente, de 100 a 500 clusters, com incremento de 5 em 5.

O grupo dos indicadores dados gerais apresentou capacidade em diferenciar municípios em níveis mais agregados de modo que esta capacidade de diminui em clusterização mais detalhadas, os valores iniciais do critério de silhueta foram elevados, porém reduziram à medida que k incrementou, esse comportamento é acompanhado por aumento da razão das variâncias (VRC), mas com piora relativa do BIC, valores menos negativos, indicando maior complexidade sem ganho proporcional de qualidade, enquanto o índice de Jaccard apresenta variação moderada de 0,3136 a 0,9550 (Figura 12).




Figura 12. Métricas dos clusters criados do grupo indicador “Dados Gerais”

Fonte: Resultados originais da pesquisa

O grupo dos indicadores população demonstrou baixa capacidade de distinção, devido os valores baixos de critério de silhueta, entre 0,2037 e 0,2141, baixa razão das variâncias (VRC), com pouca variação destas métricas ao longo de diferentes k, além do BIC crescente, evidenciando pouca melhoria na clusterização com o incremento de complexidade, também ficou comprovado o índice Jaccard em níveis moderados, comprovando baixos ganhos expressivos de estabilidade no decorrer do incremento do k (Figura 13).




Figura 13. Métricas dos clusters criados do grupo indicador “População”
Fonte: Resultados originais da pesquisa

O grupo dos indicadores educação possui boa capacidade discriminatória, onde o critério de silhueta apresenta valores moderados com leve tendencia de crescimento conforme o aumento de k evidenciando a melhoria na separação entre os clusters, a razão das variâncias (VRC) também acompanha esta comportamento de crescimento consistente, indicando aumento na diferenciação entre os grupos, o BIC apresenta melhora relativa demonstrando um equilíbrio razoável entre o ajuste e complexidade e o índice Jaccard se manteve em níveis moderados e em alguns pontos elevados indicando estabilidade consistente nos agrupamentos (Figura 14).




Figura 14. Métricas dos clusters criados do grupo indicador “Educação”
Fonte: Resultados originais da pesquisa

O grupo dos indicadores saúde comprovou que possui capacidade de diferenciação, porém limitada, de maneira que o critério de silhueta possui valores intermediários entre

0,2491 e 0,2747 indicando separação moderada, com razão das variâncias (VRC) relativamente estável e BIC crescente, comprovando o aumento da complexidade sem ganhos significativos de qualidade, o índice de Jaccard apresentou valores moderados, confirmando estabilidade aceitável dos agrupamentos (Figura 15).




Figura 15. Métricas dos clusters criados do grupo indicador “Saúde”
Fonte: Resultados originais da pesquisa

O grupo de indicadores economia evidenciou que possui forte capacidade de distinção o tornando um dos mais relevantes grupos, devido o critério de silhueta apresentou valores mais elevados, razão das variâncias (VRC) crescente e valores de BIC progressivamente melhores, menos negativos, indicando ótimo equilíbrio entre separação e ajuste, também o índice de Jaccard apresentou valores elevados em diversos pontos, sugerindo alta estabilidade dos clusters (Figura 16).




Figura 16. Métricas dos clusters criados do grupo indicador “Economia”
Fonte: Resultados originais da pesquisa

O grupo de indicadores infraestrutura demonstrou comportamento similar ao do grupo de indicadores educação, de modo que sua diferenciação ocorre mais por reorganização interna dos grupos do que por separação efetiva, de maneira apresentou o critério de silhueta moderada, razão das variâncias (VRC) decrescente e BIC crescente com o incremento do k, confirmando a não melhora na separação entre os clusters e o índice de Jaccard possui níveis moderados comprovando estabilidade, porém sem ganhos estruturais relevantes (Figura 17).




Figura 17. Métricas dos clusters criados do grupo indicador “Infraestrutura”

Fonte: Resultados originais da pesquisa

Utilizando as métricas dos grupos de indicadores normalizadas foi realizado para cada k o cálculo do score, form. (10), de modo que baseado nestes scores foi obtido o melhor k, form. (11), assim determinando qual o número de clusters mais adequado para cada grupo de indicador (Tabela 8).

Tabela 11. Melhor K por grupo indicador

Grupo Indicador	Melhor k	Razão Variância	BIC	Índice de Silhueta	Índice Jaccard
Dados Gerais	120	26645,8	-66086,8	0,370386	0,571534
População	115	927,244	5841,39	0,214128	0,329338
Educação	495	458,876	-22926,4	0,259660	0,434605
Saúde	465	947,857	47099,4	0,274738	0,387022
Economia	380	5351,07	-23046,6	0,456632	0,520485
Infraestrutura	480	1437,61	60197,6	0,276627	0,429897

Fonte: Resultados originais da pesquisa

Ficou evidenciado que as características anteriormente identificadas através das métricas foram refletidas no cálculo do melhor k por grupo de indicador onde: (i) dados gerais

ficou entre os dois menores melhores k corroborando que possui queda na qualidade quando incrementado o k; (ii) população teve o menor melhor k evidenciando que possui a menor variação estrutural; (iii) educação, saúde e infraestrutura confirmaram que possuem as maiores capacidades de distinção entre os clusters e (iv) economia também confirmou a alta capacidade de distinção entre os clusters, porém devido a maior Razão Variância indicou que esta distinção se encontra bem definida em níveis intermediários de k.

Utilizando os clusters mais adequados por grupo de indicador, foi desenvolvido a clusterização “final” de modo que esta clusterização fosse executada da mesma maneira das clusterizações anteriores, de 100 a 500 clusters, com incremento de 5 em 5.

A clusterização “final” conseguiu capturar padrões gerais de similaridade entre os municípios, porém com limitações para análises muito granulares, indicando a interpretação dos clusters como aproximação de similaridade e não como segmentações rigidamente definidas, devido os baixos valores de critérios de silhueta, variando de 0,1501 a 0,1589 comprova separação moderada a baixa entre os clusters, a razão das variâncias (VRC) possui tendência decrescente, de modo que evidencia queda na capacidade de diferenciação entre os clusters com o incremento do k, o BIC apresentou tendência crescente com o incremento do k, indicando que os modelos mais complexos não refletiram em melhores ajustes e o índice Jaccard se mantém em níveis moderados, sugerindo estabilidade consistente (Figura 18).




Figura 18. Métricas dos clusters final
Fonte: Resultados originais da pesquisa

Também através do cálculo do score, form. (10), para cada k foi calculado o melhor k, form. (11), obtendo o seguinte resultado: (i) melhor k: 100; (ii) Razão Variância: 430,369; (iii) BIC: 400479; (iv) Índice de Silhueta: 0,158933 e (v) Índice Jaccard não se aplica por ser o

primeiro k. A escolha de $k = 100$ indica o melhor equilíbrio entre coesão, separação e complexidade do modelo, evitando agrupamento excessivo quando fragmentação excessiva.

A Razão de Variância (VRC = 430,369) mede a relação entre a dispersão entre os clusters e dentro deles e, por não possuir um valor ideal fixo, deve ser analisada de forma comparativa, nesse sentido, o valor observado indica boa diferenciação entre os grupos em relação aos demais k. O BIC (400.479) avalia o equilíbrio entre qualidade do ajuste e complexidade do modelo, sendo preferíveis valores menores, e o resultado obtido sugere que $k = 100$ apresenta nível adequado de complexidade frente às demais configurações. O Critério de Silhueta (0,158933), que varia de -1 a 1, indica separação baixa, valor abaixo de 0,2, porém ainda aceitável considerando a natureza contínua e a elevada complexidade dos dados socioeconômicos analisados. Por fim, o Índice de Jaccard é utilizado para avaliar a estabilidade dos clusters em diferentes execuções, não sendo aplicável ao primeiro k analisado.

Como limitações, destacam-se o uso de dados públicos, sujeitos a diferenças de atualização e possíveis subnotificações, a sensibilidade do k-means à escolha de k e ao uso da distância euclidiana em dados socioeconômicos, além da definição dos pesos no score, que constitui uma decisão metodológica do estudo.

Conclusão

Neste trabalho, foi possível aplicar o algoritmo k-means aos indicadores socioeconômicos obtidos por meio da API do Instituto Brasileiro de Geografia e Estatística (IBGE), contemplando os 5.570 municípios brasileiros. A partir dessa abordagem, foram desenvolvidas clusterizações para os seguintes grupos de indicadores: dados gerais, população, educação, saúde, economia e infraestrutura.

Os resultados obtidos evidenciam que cada grupo de indicadores apresenta comportamentos distintos durante o processo de clusterização. O grupo de dados gerais indicou redução na qualidade dos agrupamentos à medida que o número de clusters aumenta. O grupo população apresentou baixa disparidade estrutural, indicando baixa capacidade de distinção. Já os grupos educação, saúde, economia e infraestrutura demonstraram maior capacidade de distinção entre municípios, com destaque para o grupo economia, que apresentou a separação mais evidente entre os clusters, e o grupo infraestrutura, que apresentou diferenciação moderada.

Além disso, foi possível determinar o número de clusters mais adequado por grupo de indicadores, com base na combinação de métricas de validação (razão das variâncias, BIC, critério de silhueta e índice de Jaccard) ponderadas conforme critérios definidos no estudo.

Os resultados também demonstraram a possibilidade de utilizar os agrupamentos desenvolvidos por grupos de indicadores como base para o desenvolvimento de uma clusterização final dos municípios brasileiros, além de determinar a quantidade de números de clusters mais adequado a este agrupamento final.

Como contribuição, este estudo apresenta um modelo estruturado para agrupamento de municípios brasileiros a partir de indicadores públicos, que pode ser utilizado como: (i) base para estudos futuros com dados atualizados; (ii) referência metodológica para aplicação de técnicas de clusterização em dados socioeconômicos; e (iii) suporte à identificação de municípios comparáveis, auxiliando práticas de benchmarking na gestão pública e análises de mercado.

Os resultados da presente pesquisa reforçam o potencial do uso de técnicas de análise de dados e aprendizado de máquina como ferramenta de apoio à tomada de decisão baseada em evidências no contexto da gestão pública.

Agradecimento

Agradeço a Deus pela vida, à minha esposa, pela parceria, paciência e pelas abdições que tornaram possível a conclusão deste trabalho e aos meus pais, pelo apoio incondicional, incentivo constante e pelos valores que sempre nortearam minha trajetória.

Referências

- Albertin, M.R.; Elias, S.J.B.; JR., Dmontier P. A. 2021. Benchmarking Para Um Desempenho Superior. Editora Alta Books, Rio de Janeiro, RJ, Brasil. Disponível em: <https://app.minhabiblioteca.com.br/reader/books/9786555201635>. Acesso em: 04 out. 2025.
- Albertin, R.M.; Guimarães, D.V.; Riffel, E. 2021. Geografia Física do Brasil. Grupo A. Porto Alegre, RS, Brasil. Disponível em: <https://app.minhabiblioteca.com.br/books/9786556902463>. Acesso em: 04 out. 2025.
- Banhara, N.; Duarte, D.; Schreiner, G. 2023. Extração de Esquemas de Documentos JSON: O que há de Novo?. In: Anais da XVIII Escola Regional de Banco de Dados, 2023, Palmas, PR, Brasil. Anais... p. 11-20
- Cardoso, G.C.; Cardoso, V.M. 2012. Sistemas de Banco de Dados, 1ª Edição. Saraiva, Rio de Janeiro, RJ, Brasil. Disponível em: <https://app.minhabiblioteca.com.br/reader/books/9788502162839>. Acesso em: 07 out. 2025.
- Carmo, N. C.; Nunes, F G.; Santos, A. M. 2025. Território, Sociedade e Desigualdade: Uma Revisão de Literatura. Revista Verde Grande: Geografia E Interdisciplinaridade 6(01): 31-51.
- Figueiredo Filho, D. B.; Silva Jr. J. A. 2009. Desvendando os Mistérios do Coeficiente de Correlação de Pearson (r), Revista Política Hoje 18(01): 115-146

Fontana, A.; Naldi, M.C. 2009. Estudo e Comparação de Métodos para Estimação de Números de Grupos em Problemas de Agrupamento de Dados. Disponível em: https://web.icmc.usp.br/SCATUSU/RT/Relatorios_Tecnicos/BIBLIOTECA_113_RT_340.pdf. Acesso em 12 out. 2025.

Instituto Brasileiro de Geografia e Estatística [IBGE]. 2023. Cidades e Estados do Brasil: Mogi das Cruzes (SP). Disponível em: <https://cidades.ibge.gov.br/brasil/sp/mogi-das-cruzes/panorama>. Acesso em: 02 out 2025

Instituto Brasileiro de Geografia e Estatística [IBGE]. 2024. API de dados agregados do IBGE. Disponível em: <https://servicodados.ibge.gov.br/api/docs/agregados?versao=3>, Acesso em 02 out 2025

Instituto Brasileiro de Geografia e Estatística [IBGE]. 2025. Censo Demográfico 2022: Unidades de conservação: principais características das pessoas residentes e dos domicílios, por recortes territoriais e grupos populacionais específicos: resultados do universo. Disponível em: <https://biblioteca.ibge.gov.br/visualizacao/livros/liv102192.pdf>, Acesso em: 04 out 2025

Jake, V. 2025. Guia Do Python para Data Science - Tradução da Segunda Edição: ferramentas essenciais para trabalhar com dados. Alta Books, Rio de Janeiro, RJ, Brasil. Disponível em: <https://app.minhabiblioteca.com.br/reader/books/9788550821795/>. Acesso em: 12 out. 2025.

Hair Jr., Joseph F.; Black, William C.; Babin, Barry J.; et al. 2009. Análise multivariada de dados. 6. ed. Bookman, Porto Alegre, RS, Brasil. Disponível em: <https://app.minhabiblioteca.com.br/reader/books/9788577805341>. Acesso em: 08 out. 2025.

Naldi, C. M. 2011, Técnicas de combinação para agrupamento centralizado e distribuídos de dados. Tese de Doutorado em Ciências da Computação, Instituto de Ciências Matemáticas de Computação - ICMC-USP, São Carlos, SP, Brasil

Sato, E. 2025. Influência da normalização no desempenho de classificados monolíticos e combinados. Trabalho de Conclusão de Curso de Bacharelado em Estatística, Universidade Federal de São Carlos, São Carlos, SP, Brasil.

Silva, E. N. 2024. Aplicação de aprendizado de máquina na identificação de reações de pragas a compostos semioquímicos. Trabalho de Conclusão de Curso de Bacharelado em Ciência da Computação. Universidade Federal de Alagoas, Maceió, AL, Brasil.

Sousa, M.C. C. 2019. Uma análise do algoritmo k-means como introdução ao aprendizado de máquinas. Trabalho de Conclusão de Curso do Curso de Matemática. Universidade Federal do Tocantis, Araguaína, TO, Brasil.

Apêndice

A. Repositório de códigos fonte

Este repositório assegura o entendimento e possibilita reprodução do estudo, reunindo todos os scripts desenvolvidos, desde a extração dos dados até a geração os resultados, devidamente organizados, comentados e disponibilizados no repositório do GitHub abaixo:

https://github.com/evertonsmoraes/TCC_MBA_DataScience_Analytics_USP_Esalq